

Kiến trúc hệ thống & workflow

Tài liệu thiết kế tổng — đọc file này trước khi chạy bất kỳ bước nào

Tài liệu KHUNG CHUNG • áp dụng cho mọi ngách • phiên bản v2.0 • Nguồn: `framework/00_system/01_ARCHITECTURE.md` • Ví dụ minh họa: ngách **christian-blues** (12,05/20, chấm 2026-08-15)



ĐỌC NHANH TRONG 30 GIÂY

Hệ thống này làm gì: biến dữ liệu YouTube thô của một ngách thành một quyết định có bằng chứng — vào hay không, và nếu vào thì làm gì.

Ý tưởng cốt lõi: tách khung (rubric, logic lọc, runbook) khỏi dữ liệu (từng ngách). Ngách thứ hai chỉ tốn công thu thập dữ liệu, không tốn công thiết kế lại — và vì cùng rubric nên so sánh được trực tiếp.

Ràng buộc quan trọng nhất: diễn giải không được sửa ngược điểm số. Muốn đổi điểm thì đổi ngưỡng rồi chạy lại tất cả. Đây chính là thứ bảng Excel thủ công không làm được, và là lý do nó không nhất quán.

Nội dung

- Triết lý thiết kế — tách khung khỏi dữ liệu, bốn tầng xử lý
- Workflow tổng — 10 bước, cổng quyết định, hai loại câu hỏi
- Workflow dữ liệu — từ file thô đến báo cáo
- Cách agent đọc file và liên kết thông tin
- Tám agent — bảng tổng
- Nguyên tắc phân tích dữ liệu
- Quản lý trạng thái
- Pipeline code — script nào chạy lúc nào
- Sơ đồ quan hệ tài liệu
- Hệ thống này **không** làm gì


1. Triết lý thiết kế

1.1 Tách khung khỏi dữ liệu

FRAMEWORK/ · KHUNG CHUNG	NICHES/ · DỮ LIỆU RIÊNG
Rubric chấm điểm — ngưỡng cố định	christian-blues/
Logic lọc — 4 rổ, 3 tầng	ngách kế tiếp/
Đặc tả 8 agent	ngách sau nữa/
10 runbook từng bước	...


Hệ quả: ngách thứ hai chỉ tốn công **thu thập dữ liệu + chạy quy trình**, không tốn công thiết kế lại. Và vì cùng rubric, hai ngách **so sánh được trực tiếp với nhau**.

1.2 Bốn tầng xử lý — không được trộn



Tầng 4 **không được** sửa tầng 3. Muốn đổi điểm → đổi *ngưỡng* ở tầng 3 → chạy lại toàn bộ. Đây là điều bảng Excel thủ công không làm được, và là lý do nó không nhất quán.

2. Workflow tổng — 10 bước



Nét đứt = nhánh tùy chọn. STEP_04b/04g chỉ chạy khi có file ảnh, STEP_04h chỉ chạy khi có file DSP âm thanh. Cả hai **không tác động điểm số** — chúng trả lời câu hỏi khác (xem mục 2.4).

2.1 Vì sao có **CÔNG QUYẾT ĐỊNH** sau **STEP_02**

Đây là điểm khác biệt lớn nhất so với quy trình tuyến tính thông thường.

STEP_02 trả lời câu hỏi **sống còn**: *cầu có tăng nhanh hơn cung không?* Nếu **không** → mọi phân tích sau đều là **tối ưu hóa một con tàu đang chìm**.

KẾT QUẢ STEP_02	VÙNG	HÀNH ĐỘNG
$M2.4 \geq 1,0$ — cầu $\geq$ cung	ĐI TIẾP	Đi tiếp bình thường
$M2.4$ trong $[0,5 - 1,0)$	THẬN TRỌNG	Đi tiếp nhưng đổi câu hỏi : không hỏi “vào hay không” mà hỏi “vào bằng khác biệt gì”
$M2.4 < 0,5$	DỪNG	Dừng, trừ khi có lý do chiến lược khác

VÍ DỤ THẬT — VÀ BÀI HỌC L1

Khảo sát sơ bộ Christian Blues báo $M2.4 \approx 0,35$ → rơi vào vùng **dừng**. Nhưng con số đó **SAI**: nó so cửa sổ 0–90 ngày (chỉ 36% video đã chín) với cửa sổ 90–180 ngày (100% đã chín).

Tính lại trên hai cửa sổ **đều chín** → $M2.4 = 1,305$, ngách khỏe. **Công quyết định suýt loại nhầm một ngách tốt.**

2.2 Vì sao **STEP_05** và **STEP_06** chạy sau **STEP_04**

Không phải thứ tự tùy tiện:

- **STEP_04 chọn ra video thắng** → STEP_05 chỉ đọc comment **của những video đó** (không phải toàn bộ 145k)
- **STEP_04 loại bỏ giả thuyết sai** → STEP_06 không phí công phân tích từ khóa theo hướng đã bị bác bỏ

Đảo thứ tự sẽ phải quét toàn bộ dữ liệu → vi phạm nguyên tắc chọn lọc.

STEP_04 KHÔNG “XÁC ĐỊNH CÔNG THỨC” — BÀI HỌC T29

Nó chỉ **loại trừ** — kết quả điển hình **0/20 đặc trưng đúng vững**. Công thức sản xuất là đầu ra của **STEP_10**, bước tổng hợp sau khi đã có 04b (thumbnail thật), 05 (khán giả), 06 (từ khóa).


Đây từng là nguồn hiểu nhầm: bước tên “*Công thức thắng*” lại nằm **trước** mọi phân tích hợp thành công thức. Đã đổi tên thành **SÀNG LỌC ĐỐI CHỨNG**.

2.3 Nhánh song song

CHẠY SONG SONG ĐƯỢC	VÌ SAO
STEP_05 STEP_06	Cùng đọc output STEP_04, không phụ thuộc nhau
STEP_07 (STEP_04→06)	Chỉ cần output STEP_03
STEP_04b/04g (STEP_05→07)	Nhánh ảnh độc lập, không tác động điểm số
STEP_04h (STEP_05→07)	Nhánh nhạc độc lập, chỉ cần video_id

2.4 Hai loại câu hỏi — quyết định phương pháp

Bài học đắt nhất của dự án. Cùng một bộ dữ liệu, hai câu hỏi khác nhau đòi hai phương pháp khác hẳn. Chọn nhầm thì làm đúng quy trình mà ra sai thứ người dùng cần.




	KIỂM ĐỊNH (STEP_04, 04B)	BRIEF (STEP_04G, 04H)
Câu hỏi	Đặc điểm X có gây ra thành công?	Nhóm thành công trông thế nào?
Cần đối chứng?	Bắt buộc (rổ B4)	Không
Cần kiểm Simpson?	Bắt buộc 3 lớp	Không
Nguồn	toàn bộ + rổ đối chứng	chỉ top 5%
Đầu ra	xác nhận / bác bỏ	trung vị + khoảng + prompt mẫu
Kết quả điển hình	0/12 xác nhận	công thức dùng được ngay
Dùng để	quyết định vào gác	sản xuất hàng loạt

QUY TẮC

Hỏi người dùng cần **đầu ra** gì *trước khi* chọn phương pháp. Cần “tái tạo được” → làm brief. Cần “có nên tin không” → làm kiểm định.

Hai cái **không thay thế nhau**, và brief **không được** trình bày như bằng chứng nhân quả.

3. Workflow dữ liệu — từ file thô đến báo cáo




ĐIỂM MẤU CHÓT — QUY TẮC R2

metrics.json và scores.json **tách riêng**. Agent phân tích chỉ ghi vào metrics.json (số thô). Chỉ scoring_engine mới ghi scores.json. Đây là cách chống “tự chấm tự khen”.

4. Cách agent đọc file và liên kết thông tin

4.1 Nghi thức khởi động — mọi agent đều làm




Bước 4 quan trọng nhất: PROGRESS.md là **bộ nhớ chung**. Agent không đọc nó sẽ làm lại việc đã có, hoặc dùng giả định sai.

4.2 Ba cơ chế liên kết thông tin

CƠ CHẾ	DÙNG KHI	FILE
Truyền qua file	Bước sau cần output bước trước	FILE_CONTRACTS.md khai báo
Sổ chỉ số chung	Nhiều agent cùng góp số cho rubric	_state/metrics.json
Nhật ký tiến độ	Biết trạng thái toàn cục	PROGRESS.md

4.3 Ví dụ liên kết thật — A4 Audience Researcher



A4 đọc output của A3 để biết **comment nào đáng đọc** — thay vì quét 145.150 comment. Đây là cách “chọn lọc” được thực thi ở **cấp workflow**, không chỉ ở cấp lọc dữ liệu.


5. Tám agent — bảng tổng

MÃ	TÊN	STEP	ĐỌC	GHI
A0	Data Engineer	01	raw/*	processed/*.parquet
A1	Market Analyst	02	channels , videos	02_market/
A2	Competitor Analyst	03	channels , selected_videos	03_competitor/
A3	Outlier Miner	04	selected_videos , thumbnails	04_outlier/
A4	Audience Researcher	05	selected_comments , A3 output	05_audience/
A5	Keyword Analyst	06	selected_videos , A3 output	06_keyword/
A6	Monetization Analyst	07	channels , A2 output	07_monetization/
A7	Synthesizer	08	tất cả + scores.json	99_report/

Chi tiết từng agent: framework/01_agents/

6. Nguyên tắc phân tích dữ liệu

6.1 Phân tầng công cụ — tiết kiệm chi phí



Quy tắc: thống kê mô tả **không bao giờ** dùng LLM. Chỉ dùng LLM cho việc *hiểu ngôn ngữ*.

6.2 Sáu quy tắc phân tích bắt buộc

#	QUY TẮC	CHỐNG LỖI GÌ
D1	Dùng trung vị , không dùng trung bình	View phân bố đuôi dài
D2	Chuẩn hóa theo chính kênh trước khi so sánh	Kênh to video nào cũng nhiều view
D3	Chuẩn hóa theo tuổi video (vpd)	Video cũ tích view lâu hơn
D4	Luôn có nhóm đối chứng	Survivorship bias
D5	Ghi giả thuyết trước khi chạy	Confirmation bias
D6	Báo cáo cả bằng chứng phản bác	Thiên lệch xác nhận

6.3 Ba câu hỏi phải trả lời trước mọi kết luận

#	CÂU HỎI	VÌ SAO
1	So với cái gì?	Không có mốc so sánh thì con số vô nghĩa
2	Có thể do nguyên nhân khác không?	Liệt kê ít nhất một cách giải thích ngược
3	Độ tin cậy bao nhiêu?	cao / vừa / thấp, kèm lý do

7. Quản lý trạng thái

7.1 `PROGRESS.md` — bộ nhớ chung

Mỗi bước xong phải cập nhật. Định dạng cố định:

```
## STEP_02 · Quy mô & động lượng
- Trạng thái:   XONG |   ĐANG CHẠY |   CHƯA |   CHẶN
- Chạy lúc: 2026-08-15
- Output: 02_market/01_market_sizing.md
- Phát hiện chính: M2.4 = 1,305 → cầu vượt cung
- Độ tin cậy: Vừa (chỉ 1 snapshot)
- Cảnh báo cho bước sau: cần tách kênh rác khỏi kênh tốt
```

7.2 `_state/metrics.json` — sổ chỉ số


Mọi agent **thêm** vào, không ghi đè phần của agent khác:

```
{
  "niche": "christian-blues",
  "market": { "M1_1_views_month": 10573212, "...": "..." },
  "momentum": { "M2_4_demand_supply_gap": 1.305 },
  "_meta": {
    "M2_4_demand_supply_gap": {
      "source": "processed/videos.parquet",
      "computed_by": "A1",
      "confidence": "medium",
      "caveat": "chỉ 1 snapshot, suy từ published_at"
    }
  }
}
```

Trường `_meta` là **bắt buộc** — thực thi quy tắc R3 và R5. Không có nó thì con số mất khả năng truy vết.

8. Pipeline code — script nào chạy lúc nào

Mục 2 mô tả *khái niệm* các bước. Mục này map sang **file thật** để chạy.



8.1 Chạy toàn bộ bằng một lệnh

```
bash pipeline/run_all.sh # nhánh lỗi + PDF (~50 giây)
bash pipeline/run_all.sh --with-thumbs # thêm nhánh ảnh (~15 phút)
bash pipeline/run_all.sh niches/<ngách> --no-pdf # ngách khác, bỏ PDF
```


8.2 Quy ước đặt tên

TIỀN TỔ	NGHĨA
stepNN_	tương ứng STEP_NN trong 02_steps/
stepNNx_	nhánh phụ của STEP_NN (04b , 04c , 04d , 04g , 04h)
build_reportNN.py	sinh PDF cho STEP_NN
chartsNN.py	vẽ biểu đồ cho STEP_NN, chạy trước build_report
_archive/	script đã loại bỏ, không thuộc pipeline

8.3 Ba bất biến của code

#	BẤT BIẾN	VÌ SAO
1	Chỉ scoring_engine.py được ghi scores.json	Chống “tự chấm tự khen” (R2)
2	Script phân tích không sửa 00_input/raw/	Nguồn sự thật bất biến (R1)
3	Mọi script nhận niche_path làm tham số 1	Chạy được cho ngách bất kỳ

9. Sơ đồ quan hệ tài liệu



ĐỌC KHI	FILE
Lần đầu tiếp cận hệ thống	README.md → file này
Cần hiểu schema dữ liệu	02_DATA_MODEL.md
Cần hiểu cách chấm điểm	03_SCORING_RUBRIC.md
Cần biết agent đọc/ghi gì	05_FILE_CONTRACTS.md
Sắp chạy một bước	02_steps/STEP_<n>.md
Muốn biết đang ở đâu	niches/<ngách>/PROGRESS.md

10. Hệ thống này KHÔNG làm gì

Nói rõ giới hạn để không kỳ vọng sai:

KHÔNG LÀM	VÌ SAO
Không tự crawl dữ liệu	Crawl là khâu riêng, hệ thống này bắt đầu từ dữ liệu đã có
Không dự đoán view tương lai	Chỉ đo trạng thái hiện tại và xu hướng đã xảy ra
Không thay quyết định kinh doanh	Đưa bằng chứng có cấu trúc, người quyết
Không phân tích được thứ dữ liệu không có	Ví dụ: retention, CTR, traffic source — YouTube API không trả về cho kênh người khác